한국경영과학회/ 대한산업공학회 2022 춘계공동학술대회
2022.6.1~6.4/ 제주 라마다프라자호텔

사용자 생성 컨텐츠를 활용한 머신러닝 기반 K-POP 음악흥행 예측
Predicting K-POP Hit Songs Using User Generated Content Data

전종석[1], 김승호[1], 한나은[1], 오주희 교수[2],
[1]한동대학교 ICT창업학부, [2]한동대학교 경영경제학부
[1]{jongseok, 21600101, naeun}@handong.ac.kr, [2]jooheeoh@handong.edu

초록

본 연구는 사용자 기반 컨텐츠 (UGC) 생성 및 공유서비스를 제공하는 주요 플랫폼인 Tiktok, Youtube, Instagram에서 사용자들의 음악에 대한 선호도를 바탕으로, 한류의 중심으로 자리잡은 K-POP 음악의 흥행 예측 모델을 개발하는 것을 목적으로 한다. 온라인 음악차트 서비스를 제공하는 가온차트의 2019년부터 2021년 상위 100위 곡들에 대해, 탑 10위 진입 여부에 대한 머신러닝 기반 예측모델을 구축했다. 곡의 고유한 특성인 장르 및 아티스트의 특성과 같은 변수를 기반으로, 최근 스트리밍 서비스로 주목받고 있는 Spotify의 음원 특성(Acoustic Feature) 변수, 사용자들의 음악선호도를 나타내는 UGC 변수를 바탕으로, K-POP 음악시장의 흥행을 보다 밀접하게 설명하는 요인들을 탐색하고, 예측 모델의 성능을 제고하고자 한다. 머신러닝 기반의 음악 흥행 예측 모델개발을 통해 디지털 음원시장의 통찰력을 제공하고 음악 산업 프로세스 전략수립에 기반이 될 수 있다.

주제어 : K-POP, 사용자 생성 콘텐츠 (User-Generated Content: UGC), 가온차트, 예측모델, 머신러닝

1. 서론

음악 산업은 크게 유형물에 고정되어 판매되는 모든 매체와 관련 있는 오프라인 음악산업, 음원의 다운로드, 스트리밍, 벨소리 등 무형물의 형태로 판매되는 디지털 음악산업, 그리고 콘서트와 뮤지컬 등으로 나뉘는 공연산업 등으로 분류된다 [1]. 오프라인 음악시장이 전체 음악산업에서 차지하는 비중은 디지털 음악시장에 밀려 감소하고 있는 추세이다. 국제음반산업협회에 따르면 2015년 기준으로 디지털 음원 매출은 음반 매출을 뛰어 넘었으며 전 세계 대중음악 시장의 주요 수입원으로 성장하였다[2]. 현재의 음악 소비 방식은 음원 스트리밍 서비스 및 이와 함께 제공되는 음원차트를 중심으로 설명할 수 있다 [3].

국내 시장에서는 BTS를 포함한 몇몇 K-POP 가수들이 국내외에서 큰 성공을 거두며, 기록적인 수익을 올리고 있다. 이에 K-POP은 한류의 대표적인 주자로 떠오르며 세계적으로 한국 가수와 안무, 커버 곡과 관련된 컨텐츠 들이 지속적으로 생산되고 있다[4]. K-POP의 인기는 소셜 미디어 상에서 유통되는 사용자 생성 콘텐츠(UGC)의 확산을 기반으로 한다. KIAT가 발간한 “2021 음악 산업백서”에 따르면 젊은 세대를 중심으로 틱톡, 인스타그램 라이브 등의 동영상 플랫폼에서 음악을 소비하는 경향이 높아졌으며, 이에 맞춰 가수들과 음악 제작사 또한 ‘쇼트폼’, ‘해시태그 챌린지’ 등과 같은 짧은 영상을 활용한 마케팅에 주목하고 있다.

디지털 기술과 음악 산업의 발달은 소비자가 과거에는 경험할 수 없었던 새로운 방식으로 음악을 공유 및 확산할 수 있도록 한다. K-POP의 성공은 콘텐츠 자체의 경쟁력, 체계적인 마케팅과 함께, 소셜네트워크를 통한 사용자의 음악 콘텐츠 사용, UGC 생성, 배포와 같은 전반적인 소비 방식의 변화가 기여한 바가 크다. LP, 카세트 테이프, CD 등의 저장 매체를 기반으로 하는 음반 단위의 소비에서 MP3음원을 중심으로 곡단위의 판매와 유통이 중심이 되고, 이를 재생할 수 있는 기능을 탑재한 스마트폰 사용으로 소셜네트워크 플랫폼(Yotube, Tiktok, Instagram)을 통한 소비, 재생산, 배포를 통해 음원 컨텐츠에 대한 소비패턴이 결정적으로 변화하고 증가하는 계기가

되었다. 디지털 플랫폼의 발달은 과거 유행했던 노래 및 무대를 재조명하는 역주행 기록을 만들어 내는 등 사용자 생성 콘텐츠가 음악 산업에서 결코 무시할 수 없는 지표로서 자리잡고 있다[5].

이렇듯 플랫폼 서비스를 통한 음악 산업의 발전은 다량의 데이터를 생성했고, 소셜 데이터를 바탕으로 음악 산업의 현상에 대한 분석과 예측을 하는 연구가 많이 진행되고 있다. 사용자 생성 콘텐츠(UGC)는 음악 사용자의 적극적인 참여를 유도함으로써 소비자가 음악 구매 형태에 직접적인 영향을 행사할 수 있는 기반이 되고 있다. 음악산업의 음원 단위의 판매방식으로의 변화 및 소셜 플랫폼을 통한 음악의 소비 및 재생산 패턴의 변화는 같은 아티스트의 음반이라 할지라도, 음악의 특성 및 소셜 네트워크 사용자들의 선호도에 따라 다른 판매량과 흥행여부를 가져올 수 있음을 시사한다. 마이크로레벨(micro-level) 데이터라고 할 수 있는, 음원적 특성 데이터 및 사용자 기반 데이터 분석을 통해 순위예측 모델을 개발하는 것은, 경험재화 (experience goods)라고 불리는 상품 시장의 새로운 비즈니스 모델 개발에 함의점을 제공한다. 음반시장에서 아티스트가 앨범이나 노래를 발표하면 기획사, 투자자 그리고 팬층은 각각의 목적을 위해 아티스트의 새로운 음악 상품 및 프로젝트에 관심을 집중하고 준비한다[6]. 음반산업 공급사슬 전반에 걸쳐서 기획사, 공연, 매니지먼트, 광고, 소매 유통업에 이르기까지 다양한 참여자들은 “Next Hit”을 찾기 위해 빅데이터 분석을 통한 보다 효과적인 차후 마케팅 및 광고 기획 프로젝트 작업을 위해, 데이터분석에 많은 투자를 하고 있다[7]. 이를 통해 종사자들은 팬덤이 무엇을 기대하고 있는지 이해할 수 있고, 다음 곡을 기획할 때 축적된 데이터와 분석모델을 활용함으로써 수익성을 제고할 수 있다.

본 연구는 2019년부터 2021년까지 가온차트 100위에 진입했던 1143곡의 노래에 대해 기존에 음악 산업에서 예측에 활용되던 곡의 장르,아티스트/제작/배급사의 역량 데이터와 곡의 음악적 특징과 사용자 기반 생성 콘텐츠 데이터를 함께 활용하는 머신러닝 기반의 음악 흥행 예측모델을 개발하였다. 곡의 음원적 특성 및 소셜 플래폼을 통해 확대, 재생산된, 사용자 생성 콘텐츠(UGC)의 역량을 파악하는 것이, 음악 흥행 모델의 예측도를 높일 수 있는 직접적인 근거를 제공함을 확인하는 데 목적을 두었다.

2. 관련연구

2.1 K-POP과 디지털 음원시장의 성장

2011년 SM 타운 파리 콘서트의 성공을 시작으로, 유럽, 남미 등 그 활동 범위도 넓혀져 가며 각종 온라인 사이트에서 한국 가수들 관련 동영상의 높은 조회 수, 국내 아이돌 가수들의 춤을 따라 추는 ‘커버댄스’ 물결 등 케이팝 열풍이 세계적으로 일어나고 있다[8].

최근 K-POP시장은 디지털 음원을 중심으로 그 규모가 증가하고 있다. 디지털 음원 시장의 성장은 K-POP 시장의 변화를 불러왔다. 음원이 전통적인 음반 판매로 소비되는 것이 아닌 스트리밍, 다운로드, UGC 등의 형태로 소비됨에 따라 과거 흥행하지 못한 노래나 가수가 다시 주목받아 대중들에게 알려지고 있다. 유튜브 등의 뉴미디어가 UGC를 통해 제작자와 시청자가 실시간으로 소통하는 구조를 만들어 내면서, 영상의 창작자가 기업이나 기획사가 아닌 시청자 중심으로 변화되어 새로운 시청자가 자발적으로 창작자로 전환이 되어 또 다시 새로운 시청자를 유입시키는 선순환 구조를 만들어내었다[9]. 따라서 K-POP 시장의 전세계적인 흥행은 소셜미디어가 강력한 소통의 매개체로 자리 매김하고 있다는 것을 보여준다.

2.2 소셜 네트워크 플랫폼과 사용자 기반 콘텐츠(UGC)의 확산

UGC란 전문가가 아닌 일반 대중에 의해 창작되거나 생산되어 인터넷 상에서 주로 배포되는 미디어 콘텐츠로서, 주로 디지털 비디오, 팟캐스팅(podcasting), 모바일 사진 등이 대표적이다. [10] 일반인에 의해 만들어진 다양한 콘텐츠를 읽고 보고, 즐기기 위해 많은 사람들이 UGC 웹 사이트로 모여들기 시작하면서 UGC를 여러 가지 목적으로 활용할 수 있는 가능성이 매우 커졌다.[11] 콘텐츠에 사용자의 달라진 역할로 인해 UGC의 비즈니스 가치는 높아지고 있다.

소셜 미디어와 UGC의 확산은 마케팅과 소비자 행동 관련 연구의 관점 변화를 주도하고 있다[12,14]. 소비자와의 공동 창작 마케팅은 마케터들에게 비용 효율성을 제공해주며, 소비자들이 창의적이고 주도적인 방식으로 정보를 생산하고 공유하는 방식이 가능하고, 보다

타게팅된 홍보 플랫폼을 제공한다[13].

콘텐츠를 소비하는 것뿐만 아니라, 저자 및 편집자의 역할까지 모두 담당하게 된 사용자들의 파워가 증가된 것은 부인할 수 없는 사실이 되었다[15]. 사용자들은 콘텐츠에 대한 수동적 소비자 위치에서 벗어나 미디어 공급사슬에서 매우 적극적인 역할을 하고 있으며[16], UGC를 미디어 생산 과정에 사용자가 통합된 결과물로 이해할 정도로 사용자들의 역할이 중요해졌다[17]. UGC의 비즈니스적 가치는 광고수익과도 연결된다. 마케팅 관련 실무자들이 UGC를 활용한 광고효과에 주목하고 있는 이유는 UGC에 의해서 니치 미디어 마켓이 형성될 수 있기 때문이다. 따라서 UGC는 세분화된 소비자들에게 적절한 메시지를 직접 전달할 수 있는 매개체 역할을 할 것이다[11].

2.3 머신러닝 방법론과 예측모델

디지털 음원 시장의 성장으로 사용자가 생성한 데이터와 디지털 노래 데이터베이스는 음원 데이터 분석을 가능하게 한다[18]. 이에 축적된 데이터를 활용한 머신러닝으로 음악 흥행 예측 모델을 개발하는 움직임이 일어나고있다. 예측 모델을 통해 음악 산업 실무자들은 음원 흥행을 위해 음원 제작 과정에서 주요한 음악적 특징들을 고려하고 결정할 수 있으며, 이를 통해 음원 산업의 높은 제작비가 가진 위험 부담을 줄이고 가장 유망한 노래를 선정하는 기준을 마련할 수 있다[19].

음악 차트인 여부를 예측하는 연구는 특정 차트(Spotify Global Top 50, Billboard Chart)의 데이터를 수집하여 이를 차트인 노래와 아닌 노래로 분류하여 데이터를 라벨링하고, 각 노래의 특징을 파악할 수 있는 데이터를 활용하여 음원 데이터를 분석한다. 차트인 가능성을 극대화시키는 것은 음원 제작에 도움이 될 뿐만 아니라, 광고와 홍보에 대한 투자에 가장 큰 수익을 줄 수 있는 노래들을 결정하는 데결정적으로 기여한다[20]. 이를 위해 소셜 네트워크 데이터, 음악 특징 데이터, 차트의 과거 데이터를 사용해 스포티파이 탑 50 순위를 예측하거나[21], 인터넷 기사, SNS 등의 소셜 데이터와 멜론 주간차트 진입 순위의 상관관계를 분석하여 음원 흥행 예측 지표를 제안[22]하는 등의 연구가 진행되었다.

단순한 예측 지표를 제안하는 연구를 넘어 머신러닝을 활용한 연구 또한 활발히 진행된다. Spotify Web API를 통해 각 노래의 음악적 특징을 추출하여 총 4개의 모델인 Logistic Regression, Neural Network, Random Forest, Support Vector Machine을 이용해 데이터 셋을 분석하거나[23] 총 6개의 머신러닝 기법(Expectation Maximization, Logistic Regression, Gaussian Discriminant Analysis, Support Vector Machine, Decision Tree, Neural Network)를 사용하여 빌보드 차트에서 음원 흥행 예측 모델을 구축하는 등의 연구[24] 또한 활발히 진행되었다.

본 연구는 선행 연구를 기반으로, 기계학습 기법 중 Logistic Regression, Random Forest, AdaBoost, XGBoost, GBM을 이용하여 예측을 수행하였다.

3. 데이터 수집 및 전처리

3.1 데이터 수집

본 연구는 예측 모델의 종속 변수인 Top 10 진입 여부에 대한 데이터를 수집하기 위해 가온차트 데이터를 활용하였다. 가온 차트는 국내 주요 음악 웹사이트에서 스트리밍, 다운로드, BGM 판매량을 수집하여 이에 가중치를 부여한 디지털 차트를 제공한다. 또한, 국내 음반 및 음원 매출의 97% 이상에 해당하는 데이터를 구축하고 있다. 음원의 특성과 사용자 데이터를 기반으로 한 예측모델 개발을 위해, 본 연구는 2019년 1월 첫째 주(2018.12.30 ~ 2019.01.05)부터 2021년 12월 마지막 주 (2021.12.26 ~ 2022.01.01) 까지 총 157주 동안 200위에 진입한 곡들을 수집하였다. 전체 31400개의 데이터 중 Top 10 진입 여부에 대해 예측 모델의 성능을 높이기 위해 100위에 진입한 노래를 우선적으로 선별하였다. 이외 장기간 음원차트에 상주하는 중복음원 데이터 및 Spotify 음악적 특징과 사용자 생성 콘텐츠 데이터를 추출할 수 없는 데이터를 제거하고, 총 1143개의 음원 데이터를 예측 모형을 구성하기 위해 선정하였다. 예측모형의 종속변수는 가온차트에서 해당 곡이 Top 10에 진입 여부로 구성한다. 종속변수는 해당 곡이 발매 후 가온차트 기준으로 최소 한주 이상 Top10 진입 여부를 판단하여 이진변수(Top 10 O : 1 / Top10 X : 0)로 구분한다. 또한 가온차트에서 각 노래의 순위뿐만 아니라, 곡 및 아티스트의 이름 및 특성,

소속사, 배급사, 관련 정보를 수집하였다. 곡의 세부적인 음원 특징 및 장르 데이터는 Spotify의 Open API를 사용하여 각 곡에 대한 13개의 음악적 특징 변수(Genre, Danceability, Energy, Speechiness, Acousticness, Instrumentalness, Liveness, Valance, Loudness, Tempo, Key, Mode, Duration)가 추출되었다. 마지막으로, 사용자 생성 콘텐츠 데이터(UGC)는 Songstats의 API를 사용하여 수집하였다. Songstats는 사용자에게 주요 스트리밍 서비스와 다운로드 스토어에서 음악의 사용과 관련한 포괄적인 정보를 제공한다. Songstats API를 통해 "2021-12-30"일 기준 Tiktok, Youtube, Instagram의 각 노래에 대한 UGC별 조회수 합계, 좋아요 합계, 댓글수 합계를 확인하여 각 노래별 UGC 변수를 추출하였으며 각 변수에 대한 설명은 〈Table 1〉과 같다. 종속변수 별 주요 변수의 분포는 〈Figure 1〉의 분포를 나타낸다.

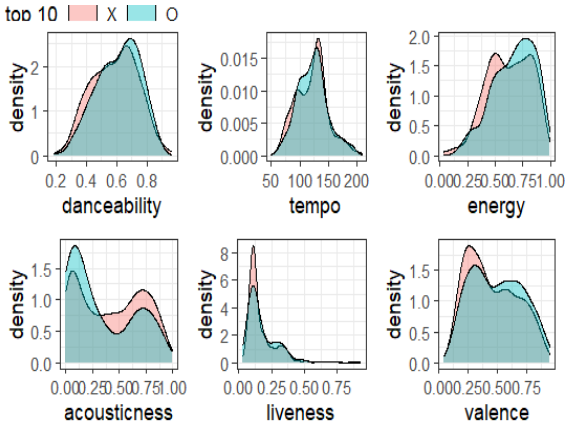

〈Figure 1〉 Distribution of Key Variables

〈Table 1〉 Description of dataset

Type	Variables	Description
DV	음원 흥행 여부	TOP 10 진입 여부, 진입시 1. 그렇지 않은 경우 0 으로 표현
IV	Distribution score	곡의 유통사 수치화
	Production score	곡의 제작사 수치화
	Artist score	가수명 수치화
	가온지수	스트리밍, 다운로드, BGM 판매량, 모바일 판매량을 합산
	Genre	Pop, Dance, Hip-hop, R&B 등 곡에 따라 15 가지 장르로 나누어짐
	Danceability	템포, 리듬 안정성, 박자 강도, 전반적인 규칙성을 포함한 음악적 요소들의 조합을 바탕으로 트랙이 춤에 얼마나 적합한지 설명 (0-1)
	Energy	강도와 활동의 지각적 측정. 에너지가 넘치는 트랙들은 빠르고, 소리가 크며, 시끄럽게 느껴짐 (0-1)
	Speechiness	트랙 내에서 스포큰 워드를 감지한다. 토크쇼, 오디오북, 시와 같이 말하는 구간이 많을수록 속성 값이 1.0 에 가까움 (0-1)
	Acousticness	트랙이 얼마나 어쿠스틱한지 설명 (0-1)
	Instrumentalness	트랙의 보컬 여부를 예측. 악기성 값이 1.0 에 가까울수록 트랙에 음성 콘텐츠가 없을 가능성이 커짐 (0-1)
	Liveness	트랙에 청중이 있는지 탐지. 높은 라이브 값은 트랙이 라이브로 수행될 확률 증가 (0-1)
	Valence	트랙이 전달하는 음악적 긍정을 설명. 이것이 높을수록 트랙은 더 긍정적으로 들리며(예: 행복, 명랑, 상쾌), 이것이 낮은 트랙은 더 부정적으로 들림(예: 슬픔, 우울, 화남) (0-1)
	Loudness	트랙의 전반적인 소리의 세기를 나타냄(dB). 소리의 세기 값은 전체 트랙에서 평균화됨 (-60 ~ 0 db)
	Tempo	전반적인 트랙의 템포는 분당 비트로 측정(BPM). 템포는 주어진 곡의 속도이며 평균 비트 지속시간에서 얻어짐
	Key	트랙의 전반적이 키를 예측. 정수는 표준 음계 표기법을 사용하여 매핑. 키가 감지되지 않으면 값은 -1. 예: 0 = C, 1 = C♯/D♭, 2 = D
	Mode	모드는 해당 트랙이 메이저 혹은 마이너인지 나타냄. Major 는 장조(맑고 부드러운 느낌), minor 는 단조(어둡고 칙칙한 느낌)로 메이저는 1, 마이너는 0
	Duration_ms	트랙의 시간을 나타냄 (milliseconds)
	View	해당 곡이 포함된 인스타그램 릴스, 틱톡 비디오, 유튜브 비디오의 조회수
	Comment	해당 곡이 포함된 인스타그램 릴스, 틱톡 비디오, 유튜브 비디오의 댓글수
	Like	해당 곡이 포함된 인스타그램 릴스, 틱톡 비디오, 유튜브 비디오의 좋아요 수

3.2 데이터 전처리

3.2.1 범주형 데이터 전처리

데이터 수집 단계에서 수집한 22개의 데이터 항목 중 수치형 데이터를 제외한 'artist', 'parent genre', 'distribution', 'production' 항목에 대하여 다음과 같은 전처리를 수행하였다. 먼저 'parent genre' 항목은 하나의 곡이 다중 장르에 속하는 것으로 분류하고 있었다. 따라서 수집한 'parent genre' 항목을 단일 범주형 변수로 구성하지 않고, 이진 변수화하여 예측 모형의 입력 변수로 사용하였다.

이외 'artist', 'distribution', 'production' 변수는 'parent genre'와 유사하게 다중으로 속해있는 가수, 배급사, 소속사가 있을 뿐만 아니라, 범주가 매우 다양하기 때문에 유의미한 변수로 사용될 가능성이 적다고 판단하였다. 그러므로 'artist score', 'distribution score', 'production score'라는 변수들을 별도로 생성하였다. 해당 변수들은 각각 데이터를 수집한 기간인 2019년부터 2021년까지 노래의 가수, 배급사, 소속사가 차트인한 횟수를 수치화한 변수이다.

3.2.2 UGC 변수 정규화 및 파생변수 생성

UGC 변수는 노래에 대한 플랫폼 별 사용자들의 사용 형태로 구성된 변수들이다. 플랫폼은 Tiktok, Youtube, Instagram으로 구성되어 있고, 사용 형태는 View, Like, Comment로 구성되어 있다. 각각의 View, Like, Comment 변수들은 플랫폼 별로 사용자의 행위가 비슷한 경향을 나타내며 그 분포가 유사하다는 점을 파악했다. 또한, 크게 히트한 곡의 경우, 극단적인 분포를 따르는 경향이 있으므로 〈Formula 1〉의 공식을 통한 표준화를 진행하여, 0부터 100까지의 범위로 수정하였고, 세 개 플랫폼의 수치를 더하여 세 가지 형태의 변수를 기록하여 사용하였다.

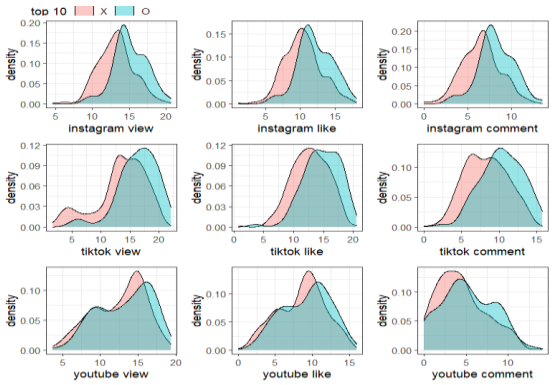

〈Figure 4〉 Distribution of UGC Variables Converted to Numerical Types

〈Formula 1〉

$$x_{scaled} = \frac{x - x_{min}}{x_{max} - x_{min}}$$

4. 결과 분석

본 연구에서는 웹 크롤링을 활용하여 수집한 1,143개 음악의 데이터와 전처리를 거쳐 생성한 파생변수를 포함하여 총 23개의 변수를 예측 모형의 입력변수로 사용하였다.

4.1 예측 모형 구축

4.1.1 사용자 생성 콘텐츠 예측 모형

본 연구는 음악이 출시되기 전, 음악의 특징들만으로 음악이 최종적으로 Top 10에 진입할 수 있는지에 대한 여부를 예측한다. 이런 관점에서 모든 변수들은 음악이 출시되기 전 파악할 수 있는 변수들로 구성했다. 사용자의 입장에서 음악이 발매된 이후 생성되는 사용자 생성 컨텐츠(UGC) 지표들은 음악이 발매되기 전에는 그 정보를 알 수 없기 때문에, 예측 모델의 변수로 부적합하다고 판단하였다. 본 연구에서는 사용자 생성 컨텐츠 변수를 예측하는 모델을 구축하여, 모델을 통해 예측된 사용자 생성 콘텐츠 값을 독립 변수로 사용함으로써, 음악이 발매되는 시점 이전에 활용될 수 있는 예측 모델을 구축하는데 주안점을 두었다. 수치형 변수인 사용자 생성 콘텐츠 값을 예측하기 위하여, 제곱 오차 (L2)를 손실 함수로 사용한 Gradient Boosting Machine을 통한 모델을 구축하였고, 예측 성능을 평가하기 위한 지표는 〈Formula2〉에 제시된 RMSE(Root Mean Square Error, 평균 제곱근 오차)를 사용하였다.

〈Formula 2〉

$$Squared\ Loss\ (L2) = \sum_{i=1}^{n} (y_{true} - y_{predicted})^2$$

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n} (y_{pred} - y_{predicted})^2}$$

예측된 모델의 타당성을 검증하기 위하여, K겹 교차검증(K Folds Cross Validation) 기법을 통하여 모형의 성능 검증을 진행하였고, 이 때

K=10으로 선정하였다. 그 결과 선정된 최적의 예측값과 실제 사용자 생성 콘텐츠 값에 대한 view, comment, like 각각의 RMSE는 〈Table 2〉와 같다.

〈Table 2〉 RMSE of predicted view, comment, like

Type	RMSE
View	8.783829
Comment	8.515473
Like	8.051986

4.1.2 Top 10 진입 여부 예측 모형

예측 모형 훈련을 위해 전체 1,143개의 음악 중 2019년부터 2020년까지의 656개의 음악을 훈련 데이터로, 2021년의 487개의 음악을 평가 데이터로 사용하였다. 노래는 발매된 시기로 구분하였다. 예를 들어, 2019년에 발매된 음악이 2021년 차트에도 존재할 경우, 해당 노래는 2019년에 발매된 노래이기 때문에 훈련 데이터로 선정하였다. 훈련 데이터와 평가 데이터의 종속변수(Top 10 진입 여부)에 대한 비율은 훈련데이터는 Top 10 진입한 종속변수의 개수가 133개, 진입하지 못한 변수의 수가 523개로 그 비율이 각각 20.3%, 79.7%였다. 평가데이터는 Top 10에 진입한 종속변수의 개수가 107개, 진입하지 못한 변수의 개수가 380개로 그 비율이 각각 22.0%, 78.0%였다.

종속변수인 음악의 'Top 10 진입 여부'는 0 또는 1의 값을 갖는 이진 변수에 해당한다. 본 연구에서는 종속 변수가 범주형일 경우 사용 가능한 일반화 선형 모형인 Logistic Regression Model과 함께 의사결정트리 기반의 앙상블 방법론 중 배깅 기법이 적용된 Random Forest, 부스팅 기법이 적용된 Ada-Boost, Gradient Boosting Machine, XGBoost 총 5 가지 모형을 구축하여 실험을 진행하였다. 각각의 모형에 대해, 사용자가 설정할 수 있는 Hyperparameter 값과 모델에 투입된 변수에 따라 성능이 달라질 수 있기 때문에, 모형별로 최적의 변수와 하이퍼파라미터 값에 대한 탐색이 필요했다. 본 연구에서는 분류 정밀도(precision)과 재현율(recall)이 함께 고려된 F1 Score를 기준으로 그리드 서치(grid-search)를 통해 최적의 하이퍼파라미터 값을 선정하였고, 단계별 변수 선택 (Stepwise Regression)을 통하여 최적의 변수를 선정하였다.

4.2 모형 성능 평가

각 모형의 예측 결과에 대해, 4개의 평가 척도를 통해 성능 평가를 진행했다. 이진 분류 모델의 성능평가는 정오행렬(confusion matrix)를 기반으로 산출 가능하다. 해당 연구에서 정오행렬은 '실제 Top 10 진입한 곡이 Top 10 진입한 곡으로 예측된 경우(TP)', '실제 Top 10 진입한 곡이지만 Top 10 진입한 곡으로 예측하지 못한 경우(FN)', 'Top 10 진입한 곡으로 예측했지만, 실제 Top 10 진입한 곡이 아닌 경우(FP)', 'Top 10 진입한 곡으로 예측하지 않았고, 실제 Top 10 진입한 곡이 아닌 경우(TN)'로 구성되었다. 정확도는 예측이 정답과 얼마나 정확한지 나타내는 지표로 TP와 TN을 더하여 TP, TN, FP, FN으로 나눈 것으로 산출한다. 정밀도는 TP를 TP와 FP을 더하여 나눈 값으로 예측한 값들 중 정답의 비율이다. 재현율은 TP를 TP와 FN을 더하여 나눈 값으로 찾아야 할 값 중에 실제로 찾은 비율을 의미한다. F1 Score는 정밀도와 재현율의 조화 평균을 통해 구할 수 있다. 모형별 최적 하이퍼파라미터 탐색과 변수 선택을 거쳐 최종 구축된 5개 모형을 통해 학습 데이터와 평가 데이터의 곡들에 대한 'Top 10 진입 여부'에 대한 예측 성능을 평가한 결과는 〈Figure 5〉, 〈Table 5〉와 같다.

〈Figure 5〉 Evaluation Results for Train & Test Data

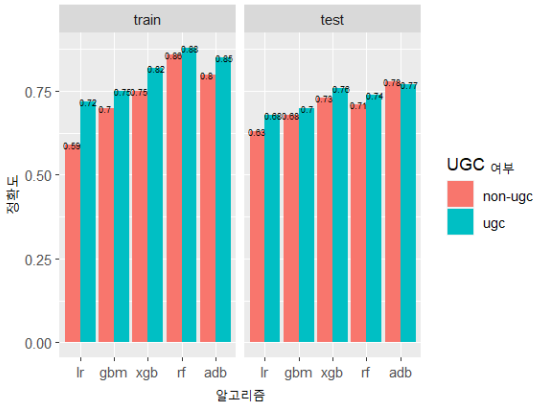

Recall 값과 Precision을 반영한 결과값인 F1 Score과 Accuracy의 측면에서 의사결정나무 기반의 boosting 기법을 적용한 XG-Boost와 Adaboost의 성능이 가장 높게 측정되었다. 또한, 사용자 생성 콘텐츠로부터 추출한 파생변수인 View, Like, Comment를 사용했을 때의 예측 성능이 해당 변수들을 제외했을 때와 비교하여 실험을 진행했던 5개의 모형 모두에서 더 높게

나타나는 것을 볼 수 있다. 이를 통해 본 연구에서 사전에 가정한 사용자 생성 콘텐츠 로부터 추출한 사용자의 노래에 대한 조회수, 좋아요, 댓글 등의 반응이 Top 10 진입 여부 예측 과정에서 유의하게 작용했음을 확인할 수 있었다. 기존의 음악 산업에서 흥행을 예측하는 연구들에서 추가된 새로운 변수가 1~5% 정도의 성능 향상을 이루는 것을 확인할 수 있다. 본 연구에서 제안하는 예측 모형의 경우 평균 3.2%의 Accuracy가 향상하는 것을 확인함으로써, 해당 변수가 예측성능을 높이는 것을 확인할 수 있다.

〈Table 5〉 Evaluation Results for Train & Test Data

Model	Prediction	Accuracy	Recall	Precision	F1
Logistic Regression	Non-UGC	0.6386037	0.7786885	0.7500000	0.7640751
	UGC	0.6817248	0.8016086	0.7868421	0.7941567
	Rate of change (%)	6.752404	2.943423	4.91228	3.936995
Random Forest	Non-UGC	0.7145791	0.7903614	0.8631579	0.8251572
	UGC	0.7371663	0.8088235	0.8684211	0.8375635
	Rate of change (%)	3.16091	2.335906	0.609761	1.503507
XGBoost	Non-UGC	0.7330595	0.7938113	0.8868421	0.8383085
	UGC	0.7618070	0.7894737	0.9473684	0.8612440
	Rate of change (%)	3.921578	-0.54643	6.824924	2.735926
AdaBoost	Non-UGC	0.7638604	0.7777778	0.9763158	0.8658110
	UGC	0.7741273	0.7800830	0.9894737	0.8723898
	Rate of change (%)	1.344068	0.296383	1.347709	0.759843
GradientBoostingMachine	Non-UGC	0.6878850	0.7923077	0.8131579	0.8025974
	UGC	0.6960986	0.8558282	0.7342105	0.8402711
	Rate of change (%)	1.194037	8.01715	-9.70874	4.693972

5. 결론

본 연구는 출시된 노래가 Top 10에 진입할 여부를 예측하는 머신러닝 기반의 예측 모형을 구축하였다. 가온차트, Spotify, Tiktok, Youtube, Instagram에서 수집한 1,143개의 곡에 대해서 2019-2020년 출시된 노래를 훈련 데이터로, 2021년 출시된 노래를 평가 데이터로 설정하여, 총 5개의 예측 모형에 대하여 사용자 생성 콘텐츠의 투입에 대한 실험을 진행하였다. 사용자 생성 콘텐츠의 투입에 앞서, 사용자 생성 콘텐츠를 예측하는 모델을 개발하였고, 평균 8.45의 RMSE를 확인할 수 있었다. 예측된 사용자 생성 콘텐츠를 변수로 투입한 실험에서는 평균적으로 3.2 %의 성능이 향상됨을 확인하였다.

본 연구는 음악 예측 모델에 다양한 머신러닝 기법을 활용하여 정확도를 높이고 기존에 활용되던 음악 장르나 소속사, 배급사, 아티스트의 데이터뿐 아니라 사용자 생성 콘텐츠 변수를 활용하여 예측 성능을 유의미하게 증가시킬 수 있음을 보여준다. 음악 사용자 플랫폼에서 수집한 마이크로 (Granular-level) 데이터를 통해 개발된 예측모델은, 음악 콘텐츠 관련 업계 및 이해당사자들에게 사용자 선호도 및 음악 시장의 선호 변화를 탐색하는데 직접적인 방편을 제공한다. 차트진입 여부에 대한 정확한 예측을 바탕으로 전략수립 및 기획과정에서, 음악의 히트차트 진입 가능성을 극대화하기 위한 노래의 구성, 생산, 유포 결정에 직접적인 통찰력을 제공하며, 수요를 최적화하여 유통하는데 결정적인 도움을 제공한다. 개발된 예측 모델의 판매를 통해, 멜론, 지니, 스포티파이 등의 음악 스트리밍 업체들이 수익성 문제로 어려움을 겪고 있는 지금, 예측모델의 구축과 유통은 음반 회사 및 아티스트들의 수익 창구 다양화와 가치 창출의 혁신을 가져올 수 있을 것이다.

* "이 논문은 과학기술정보통신부의 소프트웨어중심대학 지원사업 (2017-0-00130)의 지원을 받아 수행하였음."

참고문헌

[1] 한국콘텐츠진흥원(KOCCA), 2011 음악산업백서, pp. 68, 2011.
[2] 국제음반산업협회(2021). IFPI GLOBAL MUSIC REPORT 2020.
[3] 이남미, 구요한, 유명현, & 김재현. (2019). 대중음악 흥행결정요인과 공연성과와의 관계. *한국콘텐츠학회논문지*, *19*(7), 54-66.
[4] Lee, S. H., Choi, S., & Kim, H. W. (2020). Unveiling the success factors of BTS: a mixed-methods approach. Internet Research.
[5] 한국콘텐츠진흥원(KOCCA), 2021 음악산업백서, pp. 25-27, 2021.
[6] Patel, W. byI. (2021). Data in music? 7 ways data has impacted the music industry. 440 Industries - Training For Creative Rockstars.
[7] Capodilupo, D. (2015). Big Data and analytics: The future of music marketing. Florida Atlantic University.
[8] 이오현. (2021). 케이팝 (K-pop) 의 해외수용 문화가 지닌 문화정치적 함의에 대한 연구: K-pop Random Play Dance 를 중심으로. *한국언론학보*, *65*(5), 127-170.
[9] 정승환. (2021). K-pop 음원 역주행에 대한 사례 분석: 브레이브걸스 (Brave Girls) 의 [롤린 (Rollin. 한국엔터테인먼트산업학회논문지, 15(5), 69-83.
[10] Daugherty, T., Eastin, M. S., & Bright, L. (2008). Exploring consumer motivations for creating user-generated content. Journal of interactive advertising, 8(2), 16-25.
[11] Krishnamurthy, S., & Dou, W. (2008). Note from special issue editors: Advertising with user-generated content: A framework and research agenda. Journal of Interactive Advertising, 8(2), 1-4.
[12] Nutley, M. (2007). UGC is a two-way conversation. New Media Age, 15.
[13] Hardey, M. (2011). To spin straw into gold? New lessons from consumer-generated content. International Journal of Market Research, 53(1), 13-15.
[14] Gretzel, U., Kang, M., & Lee, W. (2008). Differences in consumer-generated media adoption and use: A cross-national perspective. Journal of Hospitality & Leisure Marketing, 17(1-2), 99-120.
[15] Marketing Week. (2014). UGC's untapped potential. Marketing Week.
[16] Obrist, M., Geerts, D., Brandtzæg, P. B., & Tscheligi, M. (2008). Design for creating, uploading and sharing user generated content. In CHI'08 Extended Abstracts on Human Factors in Computing Systems (pp. 2391-2394).
[17] Bowman, S., & Willis, C. (2003). We media. How audiences are shaping the future of news. A seminal report. Reston: The Media Center at the American Press Institute.
[18] Nijkamp, R. (2018). *Prediction of product success: explaining song popularity by audio features from Spotify data* (Bachelor's thesis, University of Twente).
[19] 이도연, & 장병희. (2020). 딥러닝을 이용한 음악흥행 예측모델 개발 연구. *한국콘텐츠학회논문지*, *20*(8), 10-18.
[20] Georgieva, E., Suta, M., & Burton, N. (2018). Hitpredict: Predicting hit songs using spotify data.
[21] Araujo, C. V. S., de Cristo, M. A. P., & Giusti, R. (2019, December). Predicting music popularity using music charts. In *2019 18th IEEE International Conference On Machine Learning And Applications (ICMLA)* (pp. 859-864). IEEE.
[22] 김가연, & 김명준. (2018). 소셜 데이터 분석을 통한 음원 흥행 예측 지표 연구. *한국디지털콘텐츠학회 논문지*, *19*(6), 1105-1114.
[23] Middlebrook, K., & Sheik, K. (2019). Song hit prediction: Predicting billboard hits using spotify data. *arXiv preprint arXiv:1908.08609*.
[24] Georgieva, E., Suta, M., & Burton, N. (2018). Hitpredict: Predicting hit songs using spotify data.